

IU Internationale Hochschule
Studiengang (B. Sc. Informatik)

Art der Arbeit (Wissenschaftliche Arbeit)

**Inwieweit sind Machine-Learning-Modelle für
Netzwerk-Anomalieerkennung zwischen verschiedenen
Datensätzen übertragbar?**

Autor: Jonas Weirauch
Matrikelnummer: Matrikelnummer
Anschrift: Im Wiesengrund 19, 55286 Sulzheim
Betreuung: Betreuer:in, akademischer Titel
Abgabedatum: 30.09.2025

Inhaltsverzeichnis

Abkürzungsverzeichnis	II
1 Einleitung	1
1.1 Motivation und Problemstellung	1
1.2 Forschungsfrage und Zielsetzung	1
2 Theoretischer Hintergrund	3
3 Methodik	4
3.1 Daten	4
3.2 Modelle und Hyperparameter	4
4 Ergebnisse	5
5 Diskussion	6
6 Fazit	7
Anhangsverzeichnis	9
A Zusatzabbildungen	10
B Pseudocode	11
Nützliche LaTeX-Referenz	12

Abkürzungsverzeichnis

AUROC	Area under the Receiver Operating Characteristic
BA	Balanced Accuracy
SNR	Signal-zu-Rausch-Verhältnis

1 Einleitung

1.1 Motivation und Problemstellung

(Canadian Institute for Cybersecurity, 2024) Mit über 10,5 Billionen US-Dollar geschätzten jährlichen Schäden bis 2025 stellen Cyberangriffe eine der größten globalen Bedrohungen dar (Sharafaldin et al., 2018; World Economic Forum, 2024). Gemäß dem Global Risk Report 2024 des Weltwirtschaftsforums gehören Cyberangriffe zu den fünf bedeutendsten globalen Risiken in den nächsten Jahren, was einer Verdreifachung der finanziellen Verluste im Vergleich zu 2015 entspricht (**GlobalRiskReport2024**). Diese besorgniserregenden Statistiken unterstreichen die akute Notwendigkeit wirksamer Sicherheitsvorkehrungen zum Schutz kritischer Infrastrukturen.

Traditionelle signaturbasierte Intrusion Detection Systeme (IDS) erreichen zunehmend ihre Grenzen bei der Erkennung neuartiger Zero-Day-Exploits und unbekannter Angriffsmuster (Ring et al., 2019). Diese Systeme können lediglich bekannte Signaturen identifizieren und versagen bei der Detektion innovativer Bedrohungen. Gleichzeitig führen die steigende Vernetzung und Digitalisierung zu einer kontinuierlichen Zunahme der Angriffsvektoren und einer erhöhten Komplexität der Netzwerkkumgebungen.

Machine Learning (ML) bietet das Potenzial, diese Limitationen zu überwinden und auch bisher unbekannte Angriffsmuster aufzudecken (Vinayakumar et al., 2019). Dennoch ist die tatsächliche Wirksamkeit verschiedener ML-Modelle in heterogenen Netzwerken noch nicht vollständig geklärt. Ein kritisches Problem stellt dabei die Generalisierungsfähigkeit dar: Während Modelle auf spezifischen Trainingsdaten exzellente Leistungen erzielen, zeigen sie oft dramatische Leistungseinbußen beim Transfer auf neue Netzwerkkumgebungen oder unterschiedliche Datensätze (Ring et al., 2019).

1.2 Forschungsfrage und Zielsetzung

Diese Arbeit untersucht systematisch die Generalisierungsfähigkeit von zwölf ML-Modellen über zwei fundamental unterschiedliche Netzwerk-Datensätze hinweg. Die zentrale Forschungsfrage lautet:

„Inwieweit sind Machine-Learning-Modelle für Netzwerk-Anomalieerkennung zwischen verschiedenen Datensätzen übertragbar?“

Die Untersuchung fokussiert sich auf die Cross-Dataset-Transferierbarkeit zwischen dem NSL-KDD-Datensatz (simulierter Netzwerkverkehr von 1998 mit 125.973 Trainingsdatensätzen) und dem CIC-IDS-2017-Datensatz (realistischer Netzwerkverkehr mit 2,8 Millionen Datenpunkten aus einer fünftägigen Netzwerkkumgebung). Diese Datensätze unterscheiden sich fundamental in ihrer Datenverteilung, Merkmalsdimensionalität und den abgebildeten Angriffsszenarien.

Die konkreten Forschungsziele umfassen:

- **Vergleichende Evaluation:** Systematische Bewertung von Baseline-Modellen (Random Forest, Decision Tree, k-NN) und Advanced-Modellen (XGBoost, LightGBM, Neural Networks) hinsichtlich ihrer Intra-Dataset-Performance und Cross-Dataset-Robustheit.
- **Cross-Dataset-Transferierbarkeit:** Quantifizierung der Generalisierungslücken beim Transfer zwischen NSL-KDD und CIC-IDS-2017 sowie Identifikation der robustesten Algorithmen für

heterogene Netzwerkkumgebungen.

- **Praktische Effizienzbetrachtung:** Analyse des Trade-offs zwischen Erkennungsleistung und computational Effizienz durch systematische Messung von Trainings- und Inferenzzeiten zur Bewertung der Praktikabilität in Echtzeit-Systemen.

Die Ergebnisse sollen konkrete Handlungsempfehlungen für die effektive Anwendung von ML-Modellen in verschiedenen Netzwerkszenarien liefern und zur aktuellen Forschungslandschaft der adaptiven Anomalieerkennung beitragen.

2 Theoretischer Hintergrund

Relevante Modelle/Begriffe, z. B. Regularisierung, Bias/Varianz. Formeln werden gesetzt:

$$\hat{R}(\theta) = \frac{1}{N} \sum_{i=1}^N \ell(y_i, f_{\theta}(x_i)) + \lambda \|\theta\|_2^2, \quad (1)$$

$$\ell(y, \hat{y}) = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})]. \quad (2)$$

3 Methodik

Design, Daten, Preprocessing, Metriken, Validierung.

3.1 Daten

Kurzbeschreibung der Datensätze.

3.2 Modelle und Hyperparameter

Tabellenbeispiel mit Quellenangabe (10 pt):

Parameter	Wert A	Wert B
Lernrate	0,001	0,01
Batchgröße	64	64

Tab. 1: Beispielhafte Hyperparameter.

Eigene Darstellung.

4 Ergebnisse

Beispielabbildung mit Titel und Quelle (10 pt):




Abb. 1: Schematische Lernkurven.

Eigene Darstellung (Platzhalter).

5 Diskussion

Ergebnisse interpretieren, Limitationen, Implikationen.

6 Fazit

Zentrale Punkte, Ausblick, Handlungsempfehlungen.

Literaturverzeichnis

- Canadian Institute for Cybersecurity. (2024). IDS 2017 | Datasets | Research | Canadian Institute for Cybersecurity | UNB. Verfügbar 29. März 2025 unter <https://www.unb.ca/cic/datasets/ids-2017.html>
- Ring, M., Wunderlich, S., Scheuring, D., Landes, D., & Hotho, A. (2019). A Survey of Network-based Intrusion Detection Data Sets. *Computers & Security*, 86, 147–167. DOI: 10.1016/j.cose.2019.06.005.
- Sharafaldin, I., Habibi Lashkari, A., & Ghorbani, A. A. (2018). Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization, 108–116. DOI: 10.5220/0006639801080116.
- Vinayakumar, R., Alazab, M., Soman, K. P., Poornachandran, P., Al-Nemrat, A., & Venkatraman, S. (2019). Deep Learning Approach for Intelligent Intrusion Detection System. *IEEE Access*, 7, 41525–41550. DOI: 10.1109/ACCESS.2019.2895334.
- World Economic Forum. (2024). *Global Risks Report 2024*. World Economic Forum. Verfügbar 29. März 2025 unter <https://www.weforum.org/publications/global-risks-report-2024/>

Anhangsverzeichnis

- Anhang A: Zusatzabbildungen
- Anhang B: Pseudocode

A Zusatzabbildungen

(Optionaler Inhalt des Anhangs.)

B Pseudocode

(Optional content of the appendix.)

Nützliche LaTeX-Referenz

Zitieren nach APA 7 (biblatex-apa)

Indirektes Zitat: `\parencite{Goodfellow2016}` → (Goodfellow et al., 2016)

Mit Seitenzahl: `\parencite[S.~123]{Bishop2006}`

Direktzitat ≤40 Wörter: „...“ `\parencite[S.~45]{Hastie2009}`

Blockzitat ≥40 Wörter:

```
\begin{blockzitat}
  Langes Zitat ohne Anführungszeichen ...
\end{blockzitat}
```

Abbildungen

```
\begin{figure}[h]
  \centering
  \includegraphics[width=0.85\textwidth]{pfad/zur/datei}
  \caption{Titel der Abbildung.}
  \source{Quelle: Eigene Darstellung / Autor, Jahr, S.~xx.}
  \label{fig:beispiel}
\end{figure}
```

Querverweis: „siehe Abb. `\ref{fig:beispiel}`“.

Tabellen

```
\begin{table}[h]
  \centering
  \begin{tabular}{lcc}
    \toprule
    \textbf{Variable} & \textbf{Gruppe A} & \textbf{Gruppe B} \\
    \midrule
    x & 1{,}23 & 4{,}56 \\
    \bottomrule
  \end{tabular}
  \caption{Titel der Tabelle.}
  \source{Quelle: Eigene Darstellung.}
  \label{tab:beispiel}
\end{table}
```

Querverweis: „siehe Tab. `\ref{tab:beispiel}`“.

Gleichungen

Einzelein:

```
\begin{equation}
  E = mc^2
\end{equation}
```

Mehrzeilig (nummeriert):

```
\begin{align}
  \hat{R}(\theta) &= \frac{1}{N} \sum_{i=1}^N \ell(y_i, f_{\theta}(x_i)) + \lambda \|w\|_2^2 \\
  \ell(y, \hat{y}) &= -\big[y \log \hat{y} + (1-y) \log(1-\hat{y})\big].
\end{align}
```

Listen

```
\begin{itemize}
  \item Punkt A
  \item Punkt B
\end{itemize}

\begin{enumerate}
  \item Erstens
  \item Zweitens
\end{enumerate}
```

Fußnoten

Text\footnote{Inhalt der Fußnote in 10 pt.}

Einheiten und Zahlen (siunitx)

```
\SI{12,5}{\kilo\meter\per\hour} → 12.5 km h-1
\num{12345,678} → 12 345.678
```

Quellen in Abbildungen/Tabellen

Direkt unter \caption einfügen: \source{Quelle: ...} (10 pt).

Platzhalter & Blindtext

Platzhalterbild: `\includegraphics{example-image}` (aus Paket `mwe`).

Kurzer Blindtext:

 Lorem ipsum dolor sit amet, consectetur adipiscing elit.

Bibliografie-Einträge (BibTeX mit Biber)

Wichtige Eintragstypen:

```
@book{key,  
  author = {Nachname, Vorname},  
  year = {2023},  
  title = {Titel des Buches},  
  subtitle = {Untertitel (optional)},  
  publisher = {Verlag},  
  address = {Ort},  
  edition = {2}, % nur bei 2. Auflage oder höher  
  doi = {10.1000/xyz}  
}
```

```
@article{key,  
  author = {Nachname, Vorname and Zweiter, Autor},  
  year = {2023},  
  title = {Titel des Artikels},  
  journaltitle = {Name der Zeitschrift},  
  volume = {42},  
  number = {3},  
  pages = {123--145},  
  doi = {10.1000/xyz}  
}
```

```
@online{key,  
  author = {Nachname, Vorname},  
  year = {2023},  
  title = {Titel der Webseite},  
  url = {https://example.com},  
  urldate = {2024-01-15}  
}
```

Biber-spezifische Felder:

- `journaltitle` statt `journal` (APA-konform)

- location statt address (moderne biblatex-Syntax)
- date statt year für komplexere Datumsangaben

Code-Beispiele in LaTeX

Einfacher Python-Code:

```
1  def fibonacci(n: int) -> list[int]:
2      """Berechnet die ersten n Fibonacci-Zahlen."""
3      seq = [0, 1]
4      for i in range(2, n):
5          seq.append(seq[-1] + seq[-2])
6      return seq[:n]
7
8
9  if __name__ == "__main__":
10     print("Fibonacci(10):", fibonacci(10))
```

Listing 1: Fibonacci-Beispiel

Ausgabe:

```
Fibonacci(10): [0, 1, 1, 2, 3, 5, 8, 13, 21, 34]
```

Inline-Nutzung (LaTeX-Syntax wörtlich):

```
\begin{lstlisting}[language=Python, caption={Minimalbeispiel}, label={lst:mini}]
    def foo(x):
        return x**2
\end{lstlisting}
```

Tatsächliches Listing (ausführbarer Code):

```
1  def foo(x):
2  return x**2
```

Listing 2: Minimalbeispiel

Ausgabe:

```
>>> foo(5)
25
```

Code aus Datei einbinden: `\lstinputlisting[language=Python, caption={Script X}, label={lst:scriptx}]{path/to/script.py}`

Erweiterte LaTeX-Tipps

Mathematik:

- Inline-Mathe: $E = mc^2 \rightarrow E = mc^2$
- Display-Mathe: $[E = mc^2]$ (unnummeriert)
- Nummerierte Gleichung: $\begin{equation} \dots \end{equation}$
- Griechische Buchstaben: $\alpha, \beta, \gamma \rightarrow \alpha, \beta, \gamma$

Querverweise:

- Label setzen: $\text{\label{fig:beispiel}}$
- Verweis: $\text{\ref{fig:beispiel}}$ oder $\text{\autoref{fig:beispiel}}$
- Seitenverweis: $\text{\pageref{fig:beispiel}}$

Typografie:

- Geschützte Leerzeichen: Abb. $\sim \text{\ref{fig:1}}$
- Anführungszeichen: $\text{\enquote{Text}}$ (sprachabhängig)
- Gedankenstrich: $--$ (Bindestrich), $---$ (Gedankenstrich)
- Auslassungspunkte: $\text{\ldots} \rightarrow \dots$

Häufige Probleme und Lösungen:

- Biber-Cache löschen: $\text{biber --cache-clear}$
- Umlaute: Verwende fontspec mit LuaLaTeX/XeLaTeX
- Lange URLs: $\text{\url{\dots}}$ oder $\text{\href{url}{Text}}$
- Overfull hbox: \sloppy oder manuelle Zeilenumbrüche

Kompilierreihenfolge mit Biber

Standard: LuaLaTeX \rightarrow Biber \rightarrow LuaLaTeX \rightarrow LuaLaTeX

VS Code/Automatisierung:

- LaTeX Workshop Extension konfigurieren
- latexmkrc für automatische Biber-Ausführung
- Overleaf nutzt automatisch die richtige Reihenfolge